

Clasificación de pacientes esquizofrénicos mediante la aplicación de la transformada de wavelets a potenciales evocados

Loraine Monteagudo García
Grupo C311

L.MONTEAGUDO@ESTUDIANTES.MATCOM.UH.CU

Amanda Marrero Santos
Grupo C311

A.MARRERO@ESTUDIANTES.MATCOM.UH.CU

Manuel S. Fernandez Arias
Grupo C311

M.FERNANDEZ2@ESTUDIANTES.MATCOM.UH.CU

Juan José Lopez Martinez
Grupo C311

J.LOPEZ2@ESTUDIANTES.MATCOM.UH.CU

Tutor(es):

Lic. Camila Perez Mosquera, *Universidad de la Habana*

Msc. Elsa Santos Febles, *Centro de Neurociencias de Cuba*

Resumen

La esquizofrenia es un trastorno psiquiátrico que afecta gran parte de la población mundial. Entre sus síntomas se encuentran la incapacidad de procesar información, fundamentalmente en las tareas de atención y memoria de trabajo. Es por ello que el uso de los potenciales evocados relacionados a eventos constituye una herramienta útil para apoyar los procesos subjetivos de decisión de los especialistas médicos. El objetivo de este trabajo generar un modelo que permita distinguir pacientes esquizofrénicos de pacientes sanos utilizando el paradigma visual de la P300 y aplicando la transformada discreta de wavelets como método de extracción de características. La base de datos utilizada posee registros de potenciales evocados de 54 sujetos sanos y 54 pacientes emparejados por edad y sexo. Se aplicó la transformada discreta de wavelet con la wavelet madre Daubechies de orden 4 y el nivel 5. Se extrajeron 180 características por sujeto y se aplicó SVM como algoritmo de aprendizaje usando validación cruzada para obtener un 62.93 % de aciertos.

Abstract

Schizophrenia is a psychiatric disorder that affects a large part of the world's population. Among its symptoms are the inability to process information, mainly in attention tasks and work memory. That is why the use of evoked potentials related to events is a useful tool to support the subjective decision processes of medical specialists. The objective of this work is to generate a model that allows to distinguish schizophrenic patients from healthy patients using the visual paradigm of the P300 and applying the discrete transform of wavelets as a method of extracting characteristics. The database used has records of evoked potentials of 54 healthy subjects and 54 patients matched by age and sex. The discrete wavelet transform was applied with the Daubechies mother wavelet of order 4 and level 5. 180 characteristics were extracted per subject and SVM was applied as a learning algorithm using cross-validation to obtain a 62.93 % accuracy.

Palabras Clave: Esquizofrenia, Wavelets, EEG, P300, Daubechies, SVM

1. Introducción

La esquizofrenia es un trastorno psiquiátrico que afecta aproximadamente el 1 % de la población mundial [1]. Aunque las alucinaciones se presentan con frecuencia, el síntoma más común es la dificultad de procesar información principalmente en las tareas de atención y memoria de trabajo [2]. En la actualidad el diagnóstico de la esquizofrenia es subjetivo y se realiza mediante la evaluación del especialista a través de síntomas predefinidos y entrevistas personales. Se hace necesario contar con medidas objetivas que puedan complementar la decisión del especialista.

El electroencefalograma (EEG) es una técnica relativamente barata y no invasiva que permite medir la

actividad eléctrica del cerebro a través de electrodos colocados en el cuero cabelludo. Esta técnica ha sido ampliamente usada para estudiar los diferentes trastornos mentales como la demencia, epilepsia, disfunciones cognitivas, entre otras como la esquizofrenia [3, 4, 5]. A través del EEG se puede explorar la dinámica del cerebro durante el procesamiento de la información mediante el uso de los potenciales relacionados a eventos (ERP) [6]. Los ERP son respuestas del sistema nervioso central que están ancladas en el tiempo a un estímulo o evento. Algunos de ellos como la P300 se usan para estudiar la esquizofrenia ya que se reportan déficits en su generación en pacientes que la padecen [7]. Para generar esta respuesta se utiliza un paradigma deno-

minado *novelty oddball* que consiste en la presentación de un estímulo de manera frecuente (estándar), otro que se presenta ocasionalmente (objetivo) y un tercer estímulo (distractor) que se presenta de manera inesperada [8]. En el caso de ser un estímulo visual estos difieren en forma, color o duración de la presentación (ver Fig. 1). La P300 aparece como una deflexión en la señal alrededor de los 300 milisegundos de aparecer el estímulo infrecuente (ver Fig. 2). y en ese caso el sujeto debe discriminarlo usando, por ejemplo, el teclado. Muchos estudios reportan diferencias entre el momento que aparece la deflexión (latencia) y el tamaño de la misma (amplitud) entre los sujetos sanos y los pacientes esquizofrénicos [9]. Es por ello que en el presente trabajo proponemos la extracción de características de las señales de este tipo de ERP para el proceso de aprendizaje supervisado con el fin de detectar pacientes esquizofrénicos.




Figura 1: Paradigma Novelty oddball P300 visual

Teniendo en cuenta que la señal de los potenciales evocados relacionada a eventos es no estacionaria se analizará en el dominio tiempo-frecuencia mediante la transformada discreta de wavelets (DWT) para la extracción de características [10] y la transformada rápida de Fourier (FFT) para describir el espectro de frecuencia en las bandas obtenidas mediante wavelets.

Finalmente, se aplicarán métodos de aprendizaje automático para generar un modelo que permita complementar el diagnóstico de la esquizofrenia.

2. Materiales y Métodos

2.1 Descripción de los datos

La muestra cuenta con 54 sujetos sanos y 54 pacientes esquizofrénicos, emparejados por edad y sexo. Ambos grupos fueron evaluados con el paradigma visual P300 con estímulo frecuente consistente en un cuadrado y dos infrecuentes consistente en un círculo (distractor) y en un cuadrado más pequeño (objetivo). En el caso del estímulo objetivo el sujeto debe reaccionar presionando una tecla en el teclado. Los estímulos se presentaron en el centro de la pantalla con una proporción (80:10:10). El EEG se recogió con una frecuencia de muestreo de 256 Hz usando 64 canales montados con el sistema internacional (10/10) para la colocación de los electrodos,. Las ventanas de señal fueron seleccionadas considerando un período de 200 milisegundos pre-estímulo y 800 milisegundos post-estímulo para un total de 1 segundo de señal (ver Fig. 2). Las ventanas de señal se promediaron de acuerdo a las respuestas específicas para cada tipo de estímulo infrecuente (objetivo y distractor) por individuo, además se filtraron

y corrigieron a la línea base.

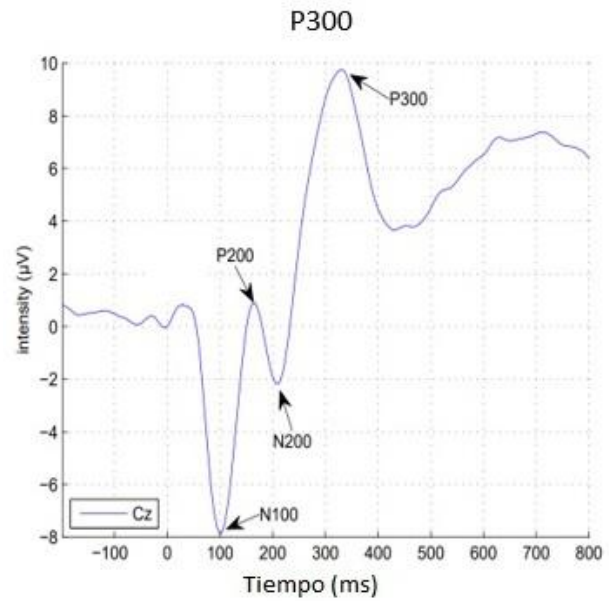


Figura 2: Respuesta de potencial evocado P300

2.2 Métodos

2.2.1 DWT

Se aplicó la DWT a los potenciales evocados promediados usando la wavelet madre Daubechies de orden 4, que es la más apropiada para detectar los cambios en la señal de EEG y que se asemeja a la onda P300 [11]. El número de nivel de descomposición se eligió de manera que las partes de la señal que se correlacionan con las frecuencias a detectar se obtuvieran en los coeficientes de la wavelet. Debemos tener en cuenta que para el estudio del EEG su espectro de frecuencia se divide en 5 bandas de frecuencias conocidas como delta [0.5-4Hz], theta [4-8Hz], alfa [8-13Hz], beta [13-30Hz] y gamma [30-45Hz] [12]. En este caso la onda P300 se encuentra entre las bandas de frecuencia correspondientes a [0-8Hz], su componente predominante se encuentra alrededor de los 2.5 Hz y existe además otro componente theta (6Hz aproximadamente) [13]. Considerando estas bandas de frecuencias de interés y la frecuencia de muestreo de 256 Hz se seleccionó el nivel de descomposición 5 (ver Fig. 3)

2.2.2 FFT

Aplicando la FFT a las señales reconstruidas a partir de los coeficientes correspondientes a las bandas de frecuencias Delta (aproximación A5) (ver Fig. 3) se puede detectar la P300 con mayor facilidad. Para ello, se analiza el espectro de frecuencia en una banda más estrecha con el fin de detectar su componente predominante determinado por el pico mayor del poder de frecuencia (ver Fig. 4). Por otra parte, se considera el promedio del poder espectral, ya que su valor puede indicar también la posible presencia de componentes

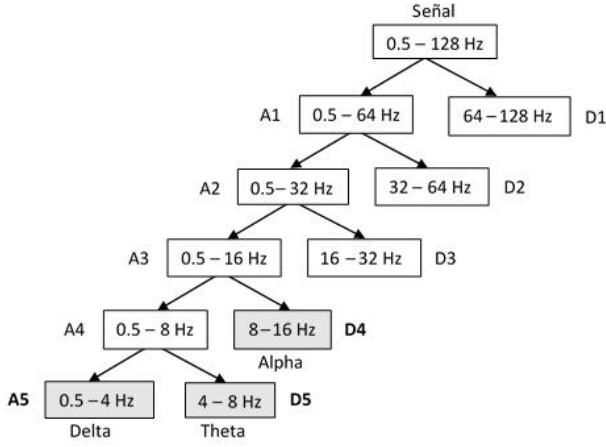


Figura 3: Descomposición por wavelets con onda madre Daubechies de orden 4, nivel 5 con una señal con frecuencia de muestreo de 256 Hz

de la P300, lo que lo hace una característica a tener en cuenta para la clasificación.




Figura 4: Cálculo de la FFT de la señal reconstruida a partir los coeficientes A5 que representa la banda Delta [0.5-4Hz]

2.3 Extracción de características

Los coeficientes de wavelets proporcionan una representación del tiempo y la frecuencia de los componentes de la P300. Diferentes características fueron extraídas de la reconstrucción de las señales correspondientes a las bandas de frecuencia a partir de los coeficientes de la aproximación A5 y los detalles D5 y D4.

En distintos trabajos [14, 15, 16] se determinan definiciones matemáticas de distintos estimadores de amplitud para actividades neurológicas. Si asumimos que la muestra n^{th} de la descomposición de wavelet en el nivel i como $D_i(n)$, entonces definimos las siguientes características:

1. *RMS* Raíz media cuadrada:

$$RMS_i = \sqrt{\frac{1}{N} \sum_{n=1}^N D_i^2(n)}$$

2. *MAV* Media:

$$MAV_i = \mu_d = \frac{1}{N} \sum_{n=1}^N |D_i(n)|$$

3. *IEEG* EEG integrado:

$$IEEG_i = \sum_{n=1}^N |D_i(n)|$$

4. *SSI* Integral cuadrada simple

$$SSI_i = \sum_{n=1}^N |D_i(n)|^2$$

5. *VAR* Varianza:

$$IEEG_i = \frac{1}{N-1} \sum_{n=1}^N D_i^2(n)$$

6. *AAC* Cambio de Amplitudes promedio:

$$AAC_i = \frac{1}{N} \sum_{n=1}^N |D_i(n+1) - D_i(n)|$$

7. *SKN* Skwness:

$$SKN_i = \sqrt{\frac{1}{6N}} \sum_{n=1}^N \left(\frac{D_i(n) - \mu_d}{\sigma_d} \right)^3$$

$$\text{Donde: } \sigma_d = \frac{1}{N} \sum_{n=1}^N (D_i(n) - \mu_d)^2$$

8. *KURT* Kurtosis:

$$KURT_i = \sqrt{\frac{N}{24}} \left\{ \frac{1}{N} \sum_{n=1}^N \left(\frac{D_i(n) - \mu_d}{\sigma_d} \right)^2 - 3 \right\}$$

9. *ENT* Shanon Entropy:

$$ENT_i = - \sum_{n=1}^N D_i^2(n) \log(D_i^2(n))$$

10. *BP* Energía promedio

Se aplica el procedimiento explicado en 2.2.2

Se obtuvieron 10 características por los tres conjuntos de coeficientes (A5, D5, D4) para un total de 30 características por tipo de estímulo (objetivo y distractor). Cada sujeto cuenta con 60 características por canal. Para reducir dimensionalidad solo se consideraron los canales de la línea media que son los más usados con este fin (Fz, Cz, Pz). Finalmente se alcanzó un total de 180 características por sujeto (ver Cuadro 1)

Sujeto							
Fz						Cz	Pz
Objetivo			Distractor				
A5	D5	D4	A5	D5	D4		
10	10	10	10	10	10		
30			30				
60						60	60

Cuadro 1: Cantidad de características por sujeto

2.4 Clasificador

El objetivo de esta fase fue desarrollar un clasificador que sea capaz de identificar cualquier combinación de la entrada como perteneciente a una de dos clases: sanos y esquizofrénicos.

La clasificación es realizada usando *Support Vector Machines* (SVM) como algoritmo de aprendizaje. Dado un conjunto de puntos, en el que cada uno de ellos pertenece a una de dos posibles categorías, un algoritmo basado en SVM construye un modelo capaz de predecir si un punto nuevo (cuya categoría desconocemos) pertenece a una categoría o a la otra. Como en la mayoría de los algoritmos basados en clasificación supervisada, los datos de entrada son vistos como un vector p -dimensional. La SVM busca un hiperplano que separe de forma óptima a los puntos de una clase u otra.

3. Resultados y Discusión

Para la realización de los experimentos los datos se dividieron de la siguiente forma: el 90 % lo constituye el conjunto de entrenamiento y el 10 % para evaluación.

Para determinar los óptimos parámetros de la SVM su uso validación cruzada de 10 iteraciones en el conjunto de entrenamiento. Los parámetros de penalización C y σ del clasificador fueron seleccionados usando este método. El rango para el parámetro del kernel fue tomado como $[0.1-15]$ con pasos de 0.1. Para el parámetro C fueron analizados los valores de 1, 5, 10, 20, 100, 500, 1000. La precisión de la SVM fue determinada cuando el set de validación fue evaluado. Los valores de los parámetros produciendo el menor error de clasificación fueron usados para la posterior construcción del clasificador.

Luego, la SVM con estos valores óptimos fue entrenado en todo el conjunto de entrenamiento y evaluado en el de prueba obteniendo un resultado de: 62.96 %

4. Conclusiones

En este trabajo se analizó la señal de los potenciales evocados relacionada a eventos que, al ser no estacionaria, se tiene en cuenta el dominio tiempo-frecuencia mediante la transformada discreta de wavelets usando Daubechies de orden 4. Además, se usó la transformada rápida de Fourier para describir el espectro de frecuencia en las bandas obtenidas mediante wavelets. Este análisis de la señal es usado para la extracción

de características para el desarrollo de un método de aprendizaje automático para generar un modelo que permita complementar el diagnóstico de esquizofrenia. A pesar de ser una primera aproximación, se obtienen resultados satisfactorios.

Referencias

- [1] Mcgrath, S. Saha, J. Welham, O. El Saadi, C. Maccauley, and D. Chant, *A systematic review of the incidence of schizophrenia: the distribution of rates and the influence of sex, urbanicity, migrant status and methodology*, vol. 22, pp. 1–22, 2004.
- [2] F. Li et al., *Top-Down Disconnectivity in Schizophrenia During P300 Tasks*, vol. 12, no. May, pp. 1–10, 2018.
- [3] A. Horvath et al., *EEG and ERP biomarkers of Alzheimer's disease: a critical review 3. EEG studies in AD*, pp. 183–220, 2018.
- [4] S. Olbrich and V. Dinteren *Personalized Medicine: Review and Perspectives of Promising Baseline EEG Biomarkers in Major Depressive Disorder and Attention Deficit*, pp. 229–240, 2016.
- [5] S. K. Loo, A. Lenartowicz, and S. Makeig, *Research Review: Use of EEG biomarkers in child psychiatry research – current state and future directions*, vol. 1, pp. 4–17, 2016.
- [6] G. F. Woodman, *A brief introduction to the use of event-related potentials (ERPs) in studies of perception and attention*, *Atten. Percept. Psychophysiol.*, vol. 72, no. 8, pp. 1–29, 2010.
- [7] E. Bramon, S. Rabe-Hesketh, P. Sham, R. M. Murray, and S. Frangou, *Meta-analysis of the P300 and P50 waveforms in schizophrenia*, *Schizophr. Res.*, vol. 70, no. 2–3, pp. 315–329, 2004.
- [8] S. Debener, S. Makeig, A. Delorme, and A. K. Engel, *What is novel in the novelty oddball paradigm? Functional significance of the novelty P3 event-related potential as revealed by independent component analysis*, vol. 22, pp. 309–321, 2005.
- [9] J. Polich, *Meta-analysis of P300 and schizophrenia: Patients, paradigms, and practical implications*, vol. 40, pp. 684–701, 2003.
- [10] V. J. Samar and K. Swartz, *Wavelet Analysis of Neuroelectric Waveforms: A Conceptual Tutorial*, vol. 60, pp. 7–60, 1999.
- [11] A. Subasi, *EEG signal classification using wavelet feature extraction and a mixture of expert model*, vol. 32, pp. 1084–1093, 2007.
- [12] G. T. Guardiola, *Conceptos básicos de electroencefalografía*, vol. 3, 2006.
- [13] B. Güntekin and E. Ba, *Review of evoked and event-related delta responses in the human brain*, 2015.

- [14] F. Sherwani, S. Shanta, B. S. K. K. Ibrahim, and M. S. Huq, *Wavelet based feature extraction for classification of motor imagery signals*, 2016 IEEE EMBS Conf. Biomed. Eng. Sci., pp. 360–364, 2016.
- [15] Y. Demir, *Wavelet-based feature extraction and selection for classification of power system disturbances using support vector machines*, vol. 80, pp. 743–752, 2010.
- [16] Phinyomark, A., Quaine, F., Laurillau, Y., Thongpanja, S., Limsakul, C., and Phukpattaranont, P. (2013). *EMG Amplitude Estimators Based on Probability Distribution for Muscle-Computer Interface*. *Fluctuation and Noise Letters*, 12(3), 1350016.